



DERİN ÖĞRENME FET 312 / 5. YARIYIL
Görüntü Tabanlı Otomatik Atık Sınıflandırma
GREENMIND

Adı-Soyadı	Öğrenci No	Gmail
Hazal Alkaya	23040101087	hazalalkaya@stu.topkapi.edu.tr
Feyza Korkmaz	23040101061	feyzakorkmaz@stu.topkapi.edu.tr
Aslıhan Erarslan	23040101020	aslihanerarslan@stu.topkapi.edu.tr
Kardelen Nur Kargacı	23040101024	kardelennurkargaci@stu.topkapi.edu.tr

GitHub Linki = https://github.com/kardelen5/FET312_GreenMind

Geri dönüşüm süreçlerinin verimli çalışması için atıkların doğru şekilde ayrıştırılması büyük önem taşır. Ancak günlük hayatta insanlar çöpü çoğunlukla rastgele atıyor ve hangi atığın hangi kutuya ait olduğunu ayırt etmekte zorlanıyor. Bu durum hem çevreye zarar veriyor hem de geri dönüşüm tesislerinde ek iş yükü oluşturuyor. Bu projede çözmek istediğimiz temel soru şudur:

“Bir çöpün fotoğrafına bakarak, onun hangi atık türüne ait olduğunu otomatik olarak nasıl belirleyebiliriz?”

Bu amaçla *Garbage Classification V2*^[1] veri setini kullanarak, çöp görüntülerini 10 farklı kategoriye ayıran bir derin öğrenme modeli geliştirmeyi hedefliyoruz. Model, gerçek hayattaki farklı ışık koşullarına, açı değişimlerine ve arka plan çeşitliliğine rağmen doğru sınıflandırma yapabilmelidir. Böyle bir sistem, akıllı geri dönüşüm kutuları veya otomatik ayrıştırma tesisleri gibi birçok alanda kullanılabilir.

Projenin Görev Türü: Çoklu sınıflandırma (multi-class image classification)

Hedef değişken: Atık türleri

Türü: Nominal

Sınıflar: Veri setindeki 10 çöp sınıfı: Pil, Biyolojik Atık, Karton, Kıyafet, Cam, Metal, Kağıt, Plastik, Ayakkabı, Atık

Birim: Yok (etiket içerir)

Bu projede modellerimizin başarısını kapsamlı bir şekilde değerlendirebilmek için, yalnızca genel doğruluğu ifade eden Accuracy değerine değil, sınıf dengesizliklerini de hesaba katan Makro F1 Skoru, modelin pozitif örnekleri ne ölçüde doğru tahmin ettiğini gösteren Precision^[18] ve gerçek pozitif örnekleri yakalama başarısını ifade eden Recall^[18] metrikleri değerlendirme sürecine dahil edilmiştir.

Bu kapsamda, hangi sınıfların sıklıkla karıştırıldığını tespit etmek için Karmaşıklık Matrisi (Confusion Matrix) analizinden, çok sınıflı problem yapısında modelin ayırım gücünü daha kapsamlı bir biçimde değerlendirebilmek adına ROC-AUC metriğinden ve eğitim sürecini değerlendirebilmek için epoch'lar boyunca kaydedilen loss ve accuracy değerlerini gösteren Eğitim Geçmiş Grafiklerinden yararlanılmıştır.

Tüm bu analizlerin sonunda modelin başarısını değerlendirebilmek için nicel performans eşikleri belirlenmiştir. Temel (base) modeller, mimari olarak sınırlı yapıya sahip olup yalnızca problemin öğrenilebilirliğini test etmeyi amaçladığından, Macro F1 skorunun en az 0.60 ve Accuracy değerinin en az 0.70 seviyesine ulaşması başarılı kabul edilmiştir.

Gelişmiş modellerde ise, daha derin mimariler ve düzenleme teknikleri kullanılması nedeniyle sınıf bazlı ayırt ediciliğin ve genel doğruluğun belirgin biçimde artması beklenmektedir. Bu doğrultuda, Macro F1 skorunun en az 0.80 ve Accuracy değerinin en az 0.85 olması, modelin hem sınıflar arası dengeyi sağladığını hem de yüksek genel performans sergilediğini göstermek açısından başarı kriteri olarak belirlenmiştir.

Proje Yönetimi

10–16 Kasım: Proje konusu seçimi ve veri seti incelemesi.

17–23 Kasım: Veri ön işleme ve veri analizi.

24 Kasım – 7 Aralık: Model tasarımı ve geliştirme.

8–21 Aralık: Hiperparametre optimizasyonu.

22 Aralık – 4 Ocak: Performans analizi ve değerlendirme.

5–18 Ocak: Son raporun hazırlanması ve proje sunumunun oluşturulması.

Roller ve Sorumluluklar:

Aslıhan Erarslan / 23040101020 : Base model için Batch Normalization ile güçlendirilmiş basit bir CNN modeli geliştirdi. Gelişmiş model aşamasında ise daha güçlü ve detaylı feature extraction sağlamak amacıyla **EfficientNet-B0^[14]** ve **ResNet-34** mimarilerini kullandı.

Kardelen Nur Kargacı / 23040101024 : Base model için CNN modelini dropout ile overfitting'e karşı güçlendirdi. Gelişmiş model aşamasında ise güçlü özellik aktarımı sağlayan **DenseNet-121^[12]** ve hafif fakat yüksek temsil gücüne sahip **ConvNeXt-Tiny^[9]** tercih ederek, daha derin ve verimli modellerle yüksek sınıflandırma performansı sağladı.

Feyza Korkmaz / 23040101061 : Projede karşılaştırma amacıyla temel bir CNN modeli tasarlanarak benchmark olarak kullandı. Nihai aşamada ise transfer öğrenme yaklaşımıyla **InceptionV3^[10]** ve **ResNet-50^[11]** mimarileri kullanılarak çöp sınıflandırma probleminde daha güçlü ve genellenebilir sonuçlar elde etti.

Hazal Alkaya / 23040101087: Atık ayrıştırma probleminin çözümünde aşamalı bir metodoloji izleyerek, projenin temel performans sınırlarını **Shallow MLP** mimarisiyle belirledi. Geliştirme sürecinde, transfer öğrenme ve hiyerarşik öznitelik haritalama yeteneklerini ölçmek amacıyla **AlexNet^[13]** modelini kullandı; final aşamasında ise gradyan kaybolması problemini "skip connections" mekanizmasıyla aşan **ResNet18** mimarisini optimize etti.

Çıktılar : https://github.com/kardelen5/FET312_GreenMind

İlgili Çalışmalar

P. Choudhary, V. Sharma, et al., "A Brief Survey of Data Preprocessing in Machine Learning and Deep Learning Technique," *Journal of Big Data*, 2021.

M. M. Hossen, et al., "Multi-layer feature fusion for high-accuracy solid waste classification using a hybrid deep learning model," *Multimedia Tools and Applications*, 2023.

E. Akın and M. E. Şahin, "Derin Öğrenme ve Yapay Sinir Ağı Modelleri Üzerine Bir İnceleme," *DergiPark*, 2022.

X. Glorot and Y. Bengio, "Understanding the difficulty of training deep feedforward neural networks," in *Proc. 13th Int. Conf. on Artificial Intelligence and Statistics (AISTATS)*, 2010.

K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2016.

S. J. Pan and Q. Yang, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, 2010.

A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.

L. Perez and J. Wang, "The Effectiveness of Data Augmentation in Image Classification using Deep Learning," *arXiv preprint arXiv:1712.04621*, 2017.

Choudhary ve Sharma (2021) tarafından yapılan "A Brief Survey of Data Preprocessing in Machine Learning and Deep Learning Technique", veri ön işleme yöntemlerini inceleyerek normalization, feature scaling ve augmentasyon gibi tekniklerin model doğruluğu ve eğitim stabilitesi üzerindeki etkilerini ortaya koymaktadır. Bu çalışmayı, base modellerimizin eğitiminde veri hazırlama ve augmentasyon stratejilerini belirlemek için referans alacağız.

Ercan Akın ve Mustafa Ergin Şahin (2022) tarafından yazılan "Derin Öğrenme ve Yapay Sinir Ağı Modelleri Üzerine Bir İnceleme", yapay sinir ağları ve derin öğrenme modellerinin temel prensiplerini ve farklı ağ mimarilerinin karşılaştırmasını sunmaktadır. Bu çalışma, Shallow MLP ve CNN base modellerimizin tasarım ve yapılandırması için rehber sağlamaktadır.

Glorot ve Bengio (2010) tarafından yayımlanan "Understanding the difficulty of training deep feedforward neural networks", shallow ve deep feedforward ağların eğitim zorluklarını inceleyerek Xavier Initialization ve $ReLU^{[5]}$ aktivasyonunun eğitim stabilitesini artırdığını göstermektedir. Shallow MLP base modelimizin eğitiminde temel bir referans olarak kullanacağız.

He ve arkadaşları (2016) tarafından sunulan "Deep Residual Learning for Image Recognition" çalışması, artık bağlantılar (residual connections) sayesinde çok derin ağların daha kolay eğitilebildiğini göstermektedir. Bu yaklaşım, projede kullanılan ResNet50 mimarisinin temelini oluşturmakta ve modelin karmaşık görsel örüntüleri öğrenmesini desteklemektedir.

Pan ve Yang (2010) tarafından yayımlanan "A Survey on Transfer Learning" çalışması, önceden eğitilmiş modellerin yeni görevlerde kullanılmasının performansı artırdığını ortaya koymaktadır. Bu yaklaşım, projede InceptionV3 ve ResNet50 modellerinin ImageNet ön eğitilmiş ağırlıklarla kullanılmasının teorik temelini desteklemektedir.

Krizhevsky, Sutskever ve Hinton (2012) tarafından yayımlanan "ImageNet Classification with Deep Convolutional Neural Networks" çalışması, derin CNN mimarilerinin görüntü sınıflandırmada yüksek başarı elde edebileceğini göstermiştir. Bu çalışma, projede kullanılan CNN tabanlı modellerin temel yapısı için önemli bir referanstır.

Perez ve Wang (2017) tarafından yapılan çalışma, veri artırma tekniklerinin modelin genelleme yeteneğini artırdığını göstermektedir. Bu bulgular, projede uygulanan veri artırma yöntemlerinin model performansına katkısını desteklemekte olduğundan bize yol gösterecektir.

Bu proje, Garbage Classification V2 veri seti üzerinde 10 farklı çöp sınıfının sınıflandırılmasına odaklanmaktadır. Literatürde bu veri setiyle yapılan çalışmaların büyük çoğunluğu, genellikle tek bir hazır derin öğrenme modeli ya da sınırlı sayıda mimari üzerinden elde edilen sonuçları raporlamakla yetinmektedir. Bu çalışmada ise mevcut yaklaşımlardan farklı olarak, uçtan uca ve aşamalı bir deneysel değerlendirme stratejisi benimsenmiştir. İlk aşamada, veri setinin temel öğrenilebilirliğini ve sınıf yapısının zorluklarını analiz edebilmek amacıyla sıfırdan tasarlanmış

farklı base CNN ve MLP mimarileri geliştirilmiş; Dropout ve Batch Normalization gibi düzenleme tekniklerinin genelleme performansı üzerindeki etkileri sistematik olarak incelenmiştir.

İkinci aşamada, elde edilen bulgular doğrultusunda daha derin ve yüksek temsil gücüne sahip mimarilere geçilerek modern pre-trained modeller üzerinde iki aşamalı Fine tuning^[15] uygulanmıştır. Toplamda 15 farklı modelin değerlendirilmesi sayesinde, basit mimarilerden gelişmiş yapılara uzanan kapsamlı, karşılaştırmalı benchmark oluşturulmuş; böylece yalnızca en iyi sonucu raporlamak yerine, hangi modelin, hangi koşullarda ve hangi sınıflarda daha etkili olduğu ayrıntılı biçimde analiz edilmiştir.

Bu yönüyle çalışma, hazır model kullanımının ötesine geçerek, veri setine özgü mimari davranışların, sınıf bazlı performans farklılıklarının ve model karmaşıklığının başarı üzerindeki etkilerini ortaya koyan bütüncül bir değerlendirme sunmaktadır.

Veri Kümesi Adı : Garbage Classification V2

Kaynak : Kaggle

Bağlantı : <https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2>

Lisans / Kullanım Hakları : Veri seti, akademik kullanım için uygundur.

Bu çalışmada Garbage Classification V2 veri seti kullanılmıştır. Veri seti, toplamda 19.762 adet RGB formatında görsel içermekte olup her bir görsel 10 farklı çöp sınıfından birine aittir. Bu sınıflar; Metal, Cam, Biyolojik, Kağıt, Pil, Genel Çöp (Trash), Karton, Ayakkabı, Giysi ve Plastik olarak belirlenmiştir.

Veri setindeki her bir görsel farklı boyutlara, açılara ve perspektiflere sahiptir. Ayrıca veri seti; farklı ışık koşulları, arka plan çeşitliliği ve çekim açıları içermektedir. Bu çeşitlilik, eğitilen modellerin gerçek dünya koşullarına daha dayanıklı ve genellenebilir olmasını sağlamaktadır. Eğitim ve test süreçlerinden önce tüm görseller ön işleme adımlarından geçirilerek sabit boyuta dönüştürülmüştür.

Garbage Classification V2 veri setindeki her örnek iki temel bileşenden oluşmaktadır:



Girdi: RGB formatında görsel (piksel değerleri her kanal için 0–255 aralığında)

Çıktı: 10 sınıfı temsil eden kategorik etiketler (0–9 aralığında)

Bu yapı sayesinde veri setindeki her örneğin giriş ve çıkış bilgileri açık bir şekilde tanımlanmış olup, derin öğrenme tabanlı sınıflandırma modellerinin eğitimi için uygundur.

Sınıf dağılımı incelendiğinde, veri setinin dengeli bir yapıya sahip olmadığı, Giysi ($\approx$ %27) ve Cam ($\approx$ %15.5) sınıflarının diğer sınıflara kıyasla daha fazla örnek içerdiği görülmektedir. Buna karşılık Pil, Metal, Biyolojik ve Genel Çöp sınıfları daha düşük oranlara sahiptir. Bu dağılım sebebiyle; eğitim sürecinde sınıf dengesizliği ihtimali göz önünde bulundurulmuş, modelin çoğunluk sınıflara yönelme riskini azaltma teknikleri kullanılmıştır.

Veri seti yalnızca çöp görsellerinden oluşmakta olup kişisel veri veya hassas bilgi içermemektedir. Bu nedenle veri gizliliği veya kimlik koruma açısından özel bir önlem alınmasına gerek yoktur.




Data Augmentation kapsamında, eğitim verileri için tüm görseller öncelikle model giriş boyutuna uyumlu olacak şekilde **yeniden boyutlandırılmış, ardından rastgele yatay çevirme, ± 15 derece rastgele döndürme, parlaklık-kontrast-doygunluk ve renk tonu değişimleri ile rastgele kırma ve yeniden ölçeklendirme** işlemleri uygulanmıştır. Bu **veri artırma** teknikleri sayesinde farklı ışık koşulları, çekim açıları ve ölçekler simüle edilerek modelin genelleme yeteneği artırılmıştır. Tüm görseller tensör formatına dönüştürülmüş ve ImageNet veri setine ait ortalama ve standart sapma değerleri kullanılarak normalize edilmiştir. Doğrulama ve test verileri için ise veri artırma uygulanmamış, yalnızca yeniden boyutlandırma ve normalizasyon işlemleri gerçekleştirilmiştir.

Veri artırma işlemleri çevrim içi olarak uygulandığından veri setinin toplam boyutu değişmemiş ve toplam 19.762 görsel korunmuştur. Sınıf dağılımı orijinal veri seti ile aynı kalmış olup genel olarak dengeli bir yapı sergilemektedir.

Veri seti, sınıflandırma problemi kapsamında **%80 eğitim (training) ve %20 test** olacak şekilde ayrılmıştır. Eğitim seti üzerinde modelin daha kararlı ve genellenebilir öğrenmesini sağlamak amacıyla **Stratified K-Fold çapraz doğrulama**^[19] yöntemi uygulanmıştır. Stratified K-Fold kullanarak her fold içinde sınıf dağılımları korunmuştur, böylece her sınıf hem eğitim hem de doğrulama aşamalarında dengeli şekilde temsil edilmiştir.

Test seti ise eğitim sürecine dahil edilmemiş ve yalnızca nihai performans değerlendirmesi için kullanılmıştır.



Yöntemler ve Mimari

Problemi çözmek için önce Garbage Classification V2 veri setindeki görüntüler ön işleme adımlarından geçirilecektir. Sonrasında, temel performansı görmek ve bir karşılaştırma zemini oluşturmak için birkaç basit **CNN** ve **MLP** tabanlı base model eğitilecektir. Son aşamada ise **EfficientNetV2**, **DenseNet-121**, **InceptionV3** ve **ConvNeXt-Tiny** gibi daha gelişmiş mimariler kullanılarak daha güçlü özellik çıkarımı yapılacak ve sonuçlar karşılaştırılarak en uygun model belirlenecektir.

Base modellerimizi bu şekilde seçmemizin nedeni, veri setinin davranışını ve modelin temel öğrenme kapasitesini objektif şekilde ölçmek istememizdir. Basit **CNN**, yapısal sadeliği sayesinde hızlı eğitilebilir ve Batch Normalization ile zenginleştirildiğinde temel bir performans referansı sunar. Dropout eklenmiş **CNN** ise overfitting eğilimini gözlemlemek ve düzenleme tekniklerinin etkisini görmek için ideal bir başlangıç noktasıdır. Temel bir **CNN** tasarlamak, feature extraction'ın en temel hâlini deneyimlemeyi sağlarken; **Shallow MLP** modeli, görüntü tabanlı görevlerde saf piksel düzeyinde öğrenmenin sınırlarını ortaya koyarak gerçek konvolüsyonel mimarilerin ne kadar kritik olduğunu anlamamıza yardımcı olur. Bu dört temel model, eğitim sürecinin nasıl davrandığını görmek ve daha gelişmiş modellere geçtiğimizde performansın ne kadar arttığını net bir şekilde karşılaştırabilmek için başlangıç noktası olarak seçilmiştir.

Projemizin bir sonraki aşamasında geliştirmeyi ve kullanmayı planladığımız gelişmiş mimarileri seçme sebebimizi şöyle açıklayabiliriz: **EfficientNetV2**'yi, dengeli ölçeklendirme stratejisi ve optimize edilmiş MBConv bloklarıyla hem yüksek doğruluk hem de verimlilik sunduğu için tercih ediyoruz; **DenseNet-121**'i, katmanlar arasındaki yoğun bağlantılar sayesinde bilgi akışını güçlendirip parametre verimliliğini artırdığı için seçtik. **ResNet**'i ise residual connections sayesinde derin ağlarda gradyan kaybını önleyerek daha kararlı ve güvenilir bir eğitim süreci sunduğu için tercih ettik. **InceptionV3**'ü multi-scale yapılandırmasıyla farklı ölçeklerdeki görsel öğeleri aynı anda yakalayarak çöp sınıflandırma gibi çeşitliliği yüksek görevlerde güçlü performans sağladığından, **ConvNeXt-Tiny**'i ise modern konvolüsyon tasarımlarıyla Transformer benzeri stabiliteyi **CNN** hızında sunarak hem derin hem de hafif bir çözüm ortaya koyduğu için tercih ettik. Bu mimarilerin her biri kendi tasarım avantajı üzerinden daha zengin temsil öğrenme, daha kararlı eğitim ve gerçek dünyaya daha iyi genelleme sunduğundan, base modellerin üzerine koyarak performansı anlamlı şekilde ileri taşımak için ideal tercihler olduğunu düşündük.

Çalışmamızın base model aşamasında Garbage Classification V2 veri setini ImageFolder yapısıyla yükleyerek tüm görüntüleri 224×224 boyutuna yeniden boyutlandırdık ve ImageNet ortalamalarıyla normalize ettik. Veri setini sınıf dağılımını koruyacak şekilde %70 eğitim, %15 doğrulama ve %15 test olarak stratified biçimde ayırdık. Base **CNN** modellerimizde 3×3 kernel boyutu, artan filtre sayıları (16'dan 128'e) ve 2×2 *max-pooling*^[6] kullandık; eğitim sürecinde ise CrossEntropyLoss ve *Adam optimizer*^[4] ile 20 epoch boyunca modeli eğittik. Performansı yalnızca doğruluk üzerinden değil, sınıf bazlı F1 skorları ve karmaşıklık matrisi ile de değerlendirerek modelin sınıflar arasındaki davranışını ayrıntılı biçimde analiz ettik.

Projemiz kapsamında, modelin kritik hiper parametresi olan Öğrenme Oranı (Learning Rate - LR) seçimi için Random Search tekniğini kullandık. Optimizasyonu hızlandırmak amacıyla, öğrenme oranı adaylarını logaritmik ölçekte 10^{-5} ile 10^{-2} aralığından rastgele seçtik. Bu adayları, kaynak verimliliğini sağlamak adına her denemede yalnızca 5 epoch süren hızlı testlere tabi tuttuk. Bu denemeler sırasında, Validasyon Doğruluğu değeri art arda 3 epoch boyunca yükselmediğinde Erken Durdurma mekanizmasını devreye sokarak stabil olmayan denemeleri sonlandırdık.

İkinci aşamada ise ImageNet üzerinde önceden eğitilmiş derin öğrenme modellerini temel alarak fine-tuning yaklaşımını kullandık. EfficientNetV2, DenseNet-121, ResNet, InceptionV3 ve ConvNeXt-Tiny mimarilerini karşılaştırmalı olarak ele aldık. Veri setini sınıf oranlarını koruyarak **%80 eğitim ve %20 test** olacak biçimde ayırdık. Eğitim sürecinin daha kararlı ve genellenebilir olması için **Stratified K-Fold çapraz doğrulama** yöntemini kullandık ve her fold içerisinde sınıf dağılımlarının korunmasına özen gösterdik.

Veri artırma kapsamında, eğitim görsellerini model giriş boyutuna uygun şekilde yeniden boyutlandırdık ve sınırlı düzeyde rastgele dönüşüm işlemleri uyguladık. Tüm görselleri tensör formatına dönüştürerek ImageNet ortalama ve standart sapma değerleri ile normalize ettik. Veri artırma işlemlerini çevrim içi uyguladığımız için veri seti boyutu değişmedi.

Model eğitiminde öğrenme oranı planlaması için **Cosine Annealing** stratejisini kullandık ve sınıf dengesizliğini azaltmak amacıyla **ağırlıklı Cross Entropy Loss** tercih ettik. Aşırı öğrenmeyi önlemek için **Early Stopping** mekanizmasını devreye aldık. Hiperparametre seçiminde **Random Search** yöntemiyle farklı yapılandırmaları değerlendirdik. Eğitim sürecini iki aşamalı olarak yürüttük; ilk aşamada yalnızca sınıflandırıcı başlığı **5 epoch**, ikinci aşamada seçilen katmanları açarak **5 epoch** fine-tuning uyguladık. En iyi yapılandırmalarla modelleri **toplam 20 epoch** boyunca eğittik. Performans analizlerini accuracy, precision, recall ve F1-score metrikleri üzerinden yaptık; ek olarak **confusion matrix** ve **sınıf bazlı performans incelemeleri ve çeşitli grafikler** ile modelleri ayrıntılı biçimde değerlendirdik.

Feyza'nın çalışmasında temel CNN modeli, sıfırdan tasarlanmış, hafif ve anlaşılır bir mimariye sahiptir. Model, ardışık evrişim katmanları ile görüntülerden özellik çıkarmakta; her katmandan sonra **ReLU aktivasyonu** ve **maksimum havuzlama** uygulanarak hem öğrenme kapasitesi artırılmakta hem de boyut azaltımı sağlanmaktadır. Özellik çıkarımından sonra elde edilen temsil, 256 nöronlu bir tam bağlantılı katmana aktarılmış ve son katmanda 10 sınıflı çıktı üretilmiştir. Hiperparametre optimizasyonu için **Random Search** kullanılmış, en iyi sonucu veren 0.003058 öğrenme oranı seçilmiştir. Eğitim sürecinde **Adam optimizasyonu**, **CrossEntropyLoss** ve **Cosine Annealing**^[17] öğrenme oranı planlayıcısı kullanılmıştır. Model 32 batch boyutu ile 20 epoch boyunca eğitilmiş ve doğrulama başarımına göre en iyi ağırlıklar kaydedilmiştir. Bu model, hafif yapısına rağmen dengeli bir temel karşılaştırma modeli sunmuştur.

InceptionV3 modeli, ImageNet üzerinde önceden eğitilmiş ağırlıklarla transfer öğrenme yaklaşımı kullanılarak projeye dahil edilmiştir. Bu mimari, aynı anda farklı boyutlardaki filtrelerle çalışarak çok ölçekli özellikler çıkarabilmekte ve karmaşık görsellerde güçlü temsil yeteneği sunmaktadır. Son sınıflandırma katmanı 10 sınıfa uyarlanmış, düşük öğrenme oranı ile Adam optimizasyonu kullanılarak ince ayar yapılmıştır. Batch boyutu 32 olarak sabit tutulmuş ve model 20 epoch boyunca eğitilmiştir. Eğitim sürecinde doğrulama performansı izlenerek en iyi model ağırlıkları seçilmiştir. InceptionV3, özellikle değişken arka planlara sahip atık görüntülerinde temel CNN'e göre daha yüksek doğruluk ve F1 skorları elde etmiştir.

ResNet50 modeli ise artık bağlantılar (**residual connections**) sayesinde derin yapılarda öğrenmeyi kolaylaştıran güçlü bir mimaridir. Model, ImageNet ön eğitilmiş ağırlıklarla başlatılmış ve son katmanı 10 sınıfa uygun hale getirilmiştir. Hiperparametre ayarlamalarında düşük öğrenme oranı tercih edilmiş, Adam ve CrossEntropyLoss kullanılmıştır. Model 32 batch boyutu ile 20 epoch eğitilmiş ve doğrulama performansına göre en iyi ağırlıklar ile değerlendirilmiştir. Derin yapısı sayesinde ResNet50, sınıflar arasındaki ince farkları yakalamada başarılı olmuş ve proje kapsamında en yüksek genel performans değerlerine ulaşan modellerden biri olmuştur.

Sonuç olarak, temel CNN modeli daha hafif ve hızlı bir çözüm sunarken, InceptionV3 çok ölçekli özellik çıkarımıyla karmaşık görüntülerde güçlü performans göstermiş, ResNet50 ise derin artık bağlantılı yapısı sayesinde en yüksek genel başarıyı sağlayan mimari olmuştur. Hiperparametre optimizasyonu ve transfer öğrenme stratejileri, tüm modellerin performansını artırmada önemli rol oynamıştır.

Aslı'nın çalışmasında hem özel tasarlanmış bir CNN mimarisi hem de ön-eğitilmiş **EfficientNet-B0** ve **ResNet-34** modelleri kullanılarak geri dönüşüm ve çöp sınıflarının otomatik olarak ayırt edilmesi amaçlanmıştır. CNN + Batch Normalization tabanlı modelde, aktivasyonların normalize edilmesi sayesinde internal covariate shift azaltılmış, gradyan kaybolması probleminin önüne geçilmiş ve modelin daha hızlı ve kararlı öğrenmesi sağlanmıştır. Bu mimari, üç adet ardışık **Conv2D katmanı**, her konvolüsyon katmanının ardından gelen **Batch Normalization** ve **ReLU aktivasyon fonksiyonları** ile **Max Pooling** katmanlarından oluşacak şekilde tasarlanmış, son aşamada ise bir **Fully Connected katman** ile sınıflandırma gerçekleştirilmiştir. Bu yapı sayesinde model, erken katmanlarda düşük seviyeli kenar ve doku bilgilerini, derin katmanlarda ise daha soyut ve ayırt edici yüksek seviyeli temsilleri öğrenebilmiştir.

CNN modelinin eğitim sürecinde, farklı öğrenme oranlarının performansa etkisini gözlemlemek amacıyla kısa bir **random search tabanlı hyperparameter tuning** uygulanmıştır. Doğrulama seti sonuçlarına göre en uygun öğrenme oranı **0.001** olarak belirlenmiş; **batch size = 32**, **Adam optimizasyon algoritması** ve **20 epoch** üzerinden nihai eğitim gerçekleştirilmiştir. Kayıp fonksiyonu olarak çok sınıflı sınıflandırma problemleri için uygun olan **CrossEntropyLoss** kullanılmış, öğrenme oranının eğitim boyunca daha verimli şekilde ayarlanması için **CosineAnnealingLR** scheduler tercih edilmiştir.

Buna ek olarak, çalışmada daha gelişmiş mimariler olan **EfficientNet-B0** ve **ResNet-34** modelleri de değerlendirilmiştir. Her iki model de ImageNet veri seti üzerinde ön-eğitilmiş ağırlıklarla başlatılmış ve **iki aşamalı transfer learning** stratejisi uygulanmıştır. İlk aşamada yalnızca sınıflandırma başlığı (head) 5 epoch boyunca eğitilmiş, böylece modele probleme özgü sınıf ayrımı kazandırılmıştır. İkinci aşamada ise üst seviye konvolüsyon katmanları açılarak 20 epoch boyunca **fine-tuning** yapılmış ve daha detaylı özelliklerin öğrenilmesi sağlanmıştır. Bu

süreçte **Random Search** ile belirlenen öğrenme oranları kullanılmış, **Cosine Annealing öğrenme oranı planlayıcısı** ve **Early Stopping** mekanizması sayesinde aşırı öğrenmenin önüne geçilmiştir.

Test seti üzerinde elde edilen sonuçlar, CNN, EfficientNet-B0 ve ResNet-34 modellerinin tamamının yüksek doğruluk (accuracy) ve **makro F1 skorları** elde ettiğini, ayrıca sınıflar arasında dengeli bir performans sergilediğini göstermektedir. Özellikle makro F1 skorlarının yüksek olması, modelin sınıf dengesizliklerinden minimum düzeyde etkilendiğini ve tüm sınıfları benzer başarıyla ayırt edebildiğini ortaya koymaktadır. Bu bulgular, kullanılan mimari yapıların, batch normalization ve transfer learning stratejilerinin geri dönüşüm sınıflandırma problemi için etkili ve güvenilir çözümler sunduğunu göstermektedir.

Kardelen'in çalışmasında **CNN + Dropout** modeli, **224×224** boyutlu RGB görüntüler üzerinde çalışan, dört ve altı evrişim bloğundan oluşan iki mimari ile çöp sınıflandırma problemine uygulanmıştır. Modelde her blokta 3×3 konvolüsyon, **ReLU aktivasyonu** ve **maksimum havuzlama** kullanılmış; aşırı öğrenmeyi azaltmak amacıyla ilk iki blokta **%25**, derin katmanlarda ise **%50 dropout** uygulanmıştır. Veri kümesi **ImageFolder** yapısı üzerinden yüklenmiş, **%70–%15–%15** oranlarında **stratified split** ile ayrılmış ve normalizasyon işlemleri torchvision^[3] dönüşümleriyle gerçekleştirilmiştir. Öğrenme oranını optimize etmek için **Random Search** uygulanmış; **Adam optimizer**, **CrossEntropyLoss**, **CosineAnnealingLR** ve **erken durdurma mekanizması** kullanılarak en iyi doğrulama başarımı elde edilmiştir.

Gelişmiş model olarak ise iki farklı **DenseNet121 tabanlı model** ve bir **ConvNeXt-Tiny tabanlı model** olmak üzere toplam **üç adet model** geliştirilmiştir. Tüm modeller **ImageNet** veri kümesi üzerinde önceden eğitilmiş ağırlıklarla başlatılmış ve **224×224** boyutlu RGB görüntüler üzerinde çalışacak şekilde yapılandırılmıştır. **DenseNet121 tabanlı modellerde**, orijinal sınıflandırıcı katman probleme özgü olarak yeniden tasarlanmış; 512 nöronlu tam bağlantılı katman, ReLU aktivasyonu ve aşırı öğrenmeyi azaltmak amacıyla Random Search ile belirlenen **optimum dropout oranı** kullanılmıştır. ConvNeXt-Tiny modelinde ise Adaptive Average Pooling, Layer Normalization, 512 nöronlu tam bağlantılı katman, **GELU^[16]** aktivasyonu ve **dropout** içeren gelişmiş bir sınıflandırıcı başlık tercih edilmiştir.

Her modelde veri kümesi **ImageFolder** yapısı kullanılarak yüklenmiş, sınıf dengesinin korunması amacıyla **Stratified K-Fold (5-fold)** yöntemi uygulanmış ve seçilen fold üzerinde **eğitim–doğrulama–test ayrımı** yaklaşık **%64–%16–%20** oranlarında gerçekleştirilmiştir. Eğitim verisi üzerinde yatay çevirme, rastgele döndürme, renk bozulmaları ve rastgele kırpmaya içeren **data augmentation** teknikleri uygulanmış; doğrulama ve test setlerinde yalnızca yeniden boyutlandırma ve ImageNet ortalama–standart sapma değerleriyle normalizasyon işlemleri yapılmıştır. Ayrıca sınıflar arasındaki dengesizliklerin etkisini azaltmak amacıyla **class-weighted CrossEntropyLoss** kullanılmıştır.

Tüm modeller için hiperparametre optimizasyonu amacıyla **Random Search** yöntemi uygulanmış; **öğrenme oranı**, **weight decay** ve **dropout oranı** olmak üzere üç temel hiperparametre **5 farklı kombinasyon** üzerinden ve her biri **5 epoch** süren kısa **head training** aşamalarında değerlendirilmiştir. İki DenseNet121 tabanlı modelde en iyi performansı sağlayan parametreler öğrenme oranı **0.0005**, weight decay **1e-05** ve dropout oranı **0.5** olarak

belirlenmiş; bu kombinasyonla birinci modelde **%95.98**, ikinci modelde ise **%95.24** doğruluk değerlerine ulaşılmıştır. ConvNeXt-Tiny modelinde ise öğrenme oranı **0.001**, weight decay **0.0001** ve dropout oranı **0.7** parametreleriyle **0.1428** doğrulama kaybı ve **%96.15** doğrulama doğruluğu elde edilerek en yüksek performans sağlanmıştır. En düşük doğrulama kaybını veren hiperparametre kombinasyonları belirlendikten sonra modeller **iki aşamalı** olarak eğitilmiştir. Phase 1 aşamasında DenseNet121 ve ConvNeXt-Tiny omurgaları tamamen dondurulmuş ve yalnızca sınıflandırıcı katmanlar **5 epoch boyunca AdamW optimizer, CosineAnnealingLR** öğrenme oranı zamanlayıcısı ve **erken durdurma mekanizması** kullanılarak eğitilmiştir. Phase 2 aşamasında ise kademeli fine-tuning stratejisi tüm modeller için uygulanmıştır. Her iki **DenseNet121** modelinde de DenseNet omurgasının son katmanları aşamalı olarak eğitime açılmış ; **farklı fine-tuning derinlikleri ve öğrenme oranları kullanılarak** probleme özgü temsillerin daha etkin biçimde öğrenilmesi sağlanmıştır. Kademeli fine-tuning uygulanan modeller teorik olarak önceden öğrenilmiş temsilleri daha kontrollü biçimde adapte ettiği için daha yüksek genelleme performansı beklenen yaklaşımdır. Ancak veri setinin boyutu ve sınıflar arası ayrışma seviyesine bağlı olarak, daha basit fine-tuning içeren modeller daha stabil sonuçlar verebilmektedir. Bu nedenle her iki yaklaşım deneysel olarak karşılaştırılmıştır. Bu karşılaştırmaya göre daha basit fine tuning uygulanan modelin(DenseNet121_1); kademeli fine tuning uygulanan modele göre(DenseNet121_2) daha iyi sonuçlar verdiği görülmüştür. **ConvNeXt-Tiny** modelinde ise son stage eğitime dahil edilerek maksimum **20 epoch** boyunca düşük bir öğrenme oranıyla tüm model hassas biçimde yeniden optimize edilmiştir. Bu yaklaşım sayesinde tüm modellerde önceden öğrenilmiş genel görsel özellikler korunurken, yüksek seviyeli ve probleme özgü özelliklerin uyarlanması başarıyla gerçekleştirilmiştir.

Hazal'ın çalışmasında, atık ayrıştırma probleminin teknik zorluklarını ve derin öğrenme mimarilerinin hiyerarşik evrimini analiz etmek amacıyla, temel piksel tabanlı yaklaşımlardan ileri seviye artık bağlantılı (residual) mimarilere uzanan, akademik titizliği yüksek ve çok katmanlı bir metodoloji izlenmiştir. Sürecin ilk basamağında, konvolüsyonel katmanların mekânsal öznitelik çıkarımındaki kritik rolünü ampirik olarak ortaya koymak amacıyla tasarlanan **Shallow MLP** modelinde, 224×224 boyutundaki RGB görüntüler düzleştirilerek 150.528 boyutlu yüksek hacimli bir giriş vektörü elde edilmiştir. Bu veri, sırasıyla 2048, 512 ve 128 nöronlu oluşan tam bağlantılı katmanlarda **ReLU** aktivasyon fonksiyonu ve %30 Dropout regülerizasyonu ile işlenmiş; logaritmik ölçekte (10^{-5} – 10^{-2}) yürütülen Random Search optimizasyonu sonucunda belirlenen 0.00002938 öğrenme oranı ile eğitilen model, %64 doğruluk ve 0.69 Makro F1 skoru seviyesinde bir baz performans (baseline) tanımlamıştır.

Projenin ikinci evresinde, mekânsal hiyerarşi ve doku temelli özniteliklerin daha etkin biçimde öğrenilmesi amacıyla ImageNet üzerinde ön-eğitilmiş (IMAGENET1K_V1) ağırlıklara sahip **AlexNet** mimarisi kullanılmıştır. Modelin beş evrim katmanı ve öznitelik haritalarındaki en baskın bilgileri seçici biçimde süzen **Maksimum Havuzlama (Max-Pooling)** katmanları sayesinde sistem, ham piksel değerlerinden ziyade nesne formlarına ve ayırt edici görsel imzalara odaklanabilmiştir. **Adam optimizer** ile eğitilen model, 5 adaylı **Random Search** süreci sonucunda valide edilen 0.000133 öğrenme oranı sayesinde doğruluğunu %93.83 seviyesine yükselterek transfer öğrenmenin problem üzerindeki etkisini açık biçimde ortaya koymuştur.

Çalışmanın final aşamasında ve en yüksek ölçülebilir performans hedefi doğrultusunda, derin ağlarda karşılaşılan **gradyan kaybolması** (vanishing gradient) problemini artık bağlantılar (Skip

Connections) aracılığıyla etkili biçimde azaltan **ResNet18** mimarisi optimize edilmiştir. Bu aşamada giriş verileri ImageNet normalizasyon standartlarına göre ölçeklendirilmiş; eğitim sürecinde öğrenme oranını her epoch sonunda adaptif olarak ayarlayan **CosineAnnealingLR** zamanlayıcısı ile doğrulama kaybı (validation loss) temelli **Erken Durdurma (Early Stopping)** mekanizması birlikte kullanılarak modelin genelleme kapasitesi maksimize edilmiştir. Beş farklı hiperparametre kombinasyonu üzerinden gerçekleştirilen arama süreci sonucunda belirlenen 0.000133 öğrenme oranı ile eğitilen ResNet18 modeli, %95.18 test doğruluğu, 0.9413 Makro F1 skoru ve yüksek kararlılığa sahip ROC-AUC eğrileri elde ederek, sınıflar arasındaki ince morfolojik farkları etkili biçimde ayırt edebilen ve bu çalışma özelinde en kararlı ve başarılı sonuçları üreten mimari olarak değerlendirilmiştir.

Deney Tasarımı

Bu çalışmada, çöp sınıflandırma problemi için geliştirilen base modeller ile gelişmiş derin öğrenme mimarilerinin performansları karşılaştırmalı olarak incelenmiştir. Deneysel süreç; veri setinin eğitim, doğrulama ve test olarak ayrılması, hiperparametre optimizasyonunun sistematik biçimde gerçekleştirilmesi, iki aşamalı eğitim stratejilerinin uygulanması ve uygun değerlendirme ölçütlerinin seçilmesi üzerine kurulmuştur. Tüm deneyler, sonuçların güvenilirliğini ve yeniden üretilebilirliğini sağlayacak şekilde açık ve tutarlı bir deney tasarımı çerçevesinde kurgulanmıştır.

1. Deney – Base Modellerin Temel Performansının Karşılaştırılması

Bu deneyin ana amacı, basit ve orta karmaşıklıkta mimarilerin çöp sınıflandırma problemindeki temel performansını ölçmek ve mimari bileşenlerin (Batch Normalization, Dropout) katkısını analiz etmektir. Bu kapsamda **6 farklı base model** geliştirilmiştir:

- Sade CNN
- CNN + Batch Normalization (4 ve 6 katmanlı)
- CNN + Dropout (4 ve 6 katmanlı)
- Shallow MLP

Veri seti, sınıf dağılımını koruyacak şekilde %70 eğitim, %15 doğrulama ve %15 test oranlarında stratified olarak bölünmüştür. Etiketler PyTorch^[2] ImageFolder yapısı ile otomatik olarak alınmıştır. Eğitim sürecinde her epoch sonunda doğrulama seti üzerinde loss ve accuracy hesaplanarak aşırı öğrenme kontrolü sağlanmıştır.

Hiperparametre optimizasyonu için her modelde kısa bir Random Search uygulanmış ve doğrulama setinde en iyi sonucu veren öğrenme oranı seçilmiştir. Modeller, Adam optimizasyonu ve CosineAnnealingLR scheduler ile eğitilmiştir. CNN tabanlı modeller 20 epoch, shallow MLP modeli ise 30 epoch boyunca eğitilmiştir.

Değerlendirme Accuracy, Macro F1 skoru, sınıf bazlı F1 skorları ve Confusion Matrix kullanılarak yapılmıştır. Accuracy genel doğruluğu ölçerken, Macro F1 sınıf dengesizliklerinin etkisini azaltmak için tercih edilmiştir.

Test seti sonuçlarına göre CNN + Batch Normalization, en yüksek Accuracy ve Macro F1 skorlarını elde ederek en başarılı base model olmuştur. Bunu sırasıyla CNN + Dropout, sade

CNN ve shallow MLP izlemiştir. Başarı sıralaması Macro F1 ve Accuracy birlikte dikkate alınarak oluşturulmuştur.

2. Deney – Gelişmiş Modellerin Karşılaştırmalı Performans Analizi

Bu deneyin amacı, farklı derinlik ve mimari tasarımlara sahip gelişmiş CNN modellerinin çöp sınıflandırma problemindeki performansını karşılaştırmaktır. Bu kapsamda **8 farklı gelişmiş** model değerlendirilmiştir:

- EfficientNet-B0
- ResNet-18
- ResNet-34
- ResNet-50
- DenseNet-121
- AlexNet
- ConvNeXt-Tiny
- Inception-V3

Tüm gelişmiş modeller ImageNet ön-eğitilmiş (pre-trained) ağırlıklarla başlatılmıştır. Eğitim, iki aşamalı strateji ile yürütülmüştür: ilk aşamada yalnızca sınıflandırıcı başlığı 5 epoch eğitilmiş, ikinci aşamada son katmanlar açılarak 20 epoch fine-tuning uygulanmıştır.

Hiperparametre seçimi için Random Search ile farklı öğrenme oranları test edilmiş, doğrulama setinde en iyi performansı veren değer kullanılmıştır. Eğitim sırasında Adam optimizasyonu ve CosineAnnealingLR scheduler tercih edilmiştir. Değerlendirme kriterleri olarak Accuracy, Macro F1, ROC-AUC (One-vs-Rest) ve Confusion Matrix kullanılmıştır.

Test seti sonuçlarına göre EfficientNet-B0 ve ConvNeXt-Tiny, en yüksek Macro F1 ve ROC-AUC değerlerini elde ederek en başarılı modeller olmuştur. ResNet34 ve DenseNet-121 dengeli performans sergilerken, AlexNet ve daha derin ResNet-50 mimarisi görece olarak daha düşük performans göstermiştir. Başarı sıralaması Macro F1 ve ROC-AUC değerleri esas alınarak yapılmıştır.

3. Deney – Sınıf Bazlı Performans ve Hata Analizi

Bu deneyin amacı, hem base hem de gelişmiş modellerin farklı çöp türleri üzerindeki davranışını ayrıntılı olarak incelemek ve sınıflar arası hata örüntülerini ortaya koymaktır. Test setindeki tüm örnekler için gerçek etiketler ve model tahminleri alınarak **sınıf bazlı Precision, Accuracy, Recall ve F1 skorları** hesaplanmıştır.

Confusion Matrix analizleri ile hangi sınıfların sıklıkla karıştırıldığı belirlenmiş ve rastgele seçilen test görüntüleri üzerinden görsel tahmin analizleri gerçekleştirilmiştir.

Sonuçlar, cardboard ve glass gibi belirgin görsel özelliklere sahip sınıflarda tüm CNN tabanlı modellerin yüksek F1 skorları elde ettiğini göstermiştir. Buna karşılık metal ve plastic gibi görsel olarak benzer sınıflarda base modellerin hata oranı artarken, **EfficientNet-B0, ResNet-34 ve DenseNet-121** bu sınıflarda daha dengeli performans sergilemiştir.

Sınıf bazlı F1 skorları ve Confusion Matrix birlikte değerlendirildiğinde, gelişmiş modellerin sınıf dengesizliklerini daha iyi yönettiği ve özellikle zor sınıflarda daha güvenilir tahminler ürettiği gözlemlenmiştir. Genel değerlendirmede başarı sıralaması, sınıf bazlı Macro F1 ve ROC-AUC kriterlerine göre yapılmıştır.

Kullanılan Araçlar ve Frameworkler

Bu çalışma Python 3.10.19 (Anaconda dağıtımı) üzerinde yürütülmüştür. Kullanılan temel kütüphaneler ve sürümleri şu şekildedir: *NumPy*^[8] 2.2.5, *Pandas* 2.3.3, *scikit-learn*^[7] 1.7.1, *PyTorch* 2.5.1+cu121 ve *torchvision* 0.20.1+cu121. Veri işleme sürecinde *PyTorch*'un *ImageFolder* yapısı ve *transforms* modülü kullanılmıştır. Tüm deneylerin tekrarlanabilir olması için sabit bir seed değeri (42) belirlenmiştir. Donanım tarafında model,CUDA 12.1 destekli bir GPU üzerinde yürütülmüştür. Çalışmanın sorunsuz yürütülebilmesi için en az 8 GB RAM gereklidir.

Kaynaklar :

[1] *Garbage Classification Dataset* = A. Thakur, "Garbage Classification Dataset," Kaggle, 2019.
[Çevrimiçi].Erişim: <https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

[2] *PyTorch* = A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," *Advances in Neural Information Processing Systems*, vol. 32, 2019.

[3] *Torchvision* = F. Massa and R. Girshick, "TorchVision: Models, Datasets and Transforms for Image Classification," *PyTorch Documentation*, 2021.

[4] *Adam Optimizer* = D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," *arXiv:1412.6980*, 2015.

[5] *ReLU Activation Function* = V. Nair and G. E. Hinton, "Rectified Linear Units Improve Restricted Boltzmann Machines," *Proceedings of the 27th International Conference on Machine Learning (ICML)*, 2010.

[6] *MaxPooling & Convolution (Temel CNN Yapısı)* = Y. LeCun, Y. Bengio, "Convolutional Networks for Images, Speech, and Time Series," *The Handbook of Brain Theory and Neural Networks*, MIT Press, 1995.

[7] *Scikit-Learn* = F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research (JMLR)*, vol. 12, pp. 2825–2830, 2011.

[8] *NumPy* = C. R. Harris et al., "Array Programming with NumPy," *Nature*, vol. 585, pp. 357–362, 2020.

[9] *ConvNeXt* = Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

[10] *InceptionV3* = C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the Inception Architecture for Computer Vision," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[11] ResNet50 = K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[12] DenseNet121 = G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[13] AlexNet = A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 25, 2012.

[14] EfficientNet = M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proceedings of the International Conference on Machine Learning (ICML)*, 2019.

[15] Fine-Tuning = S. J. Pan and Q. Yang, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, 2010.

[16] GELU Activation Function = D. Hendrycks and K. Gimpel, "Gaussian Error Linear Units (GELUs)," *arXiv preprint arXiv:1606.08415*, 2016.

[17] Cosine Annealing = I. Loshchilov and F. Hutter, "SGDR: Stochastic Gradient Descent with Warm Restarts," *Proceedings of the International Conference on Learning Representations (ICLR)*, 2017.

[18] Precision & Recall = T. Saito and M. Rehmsmeier, "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," *PLOS ONE*, vol. 10, no. 3, 2015.

[19] Stratified K-Fold Cross Validation = R. Kohavi, "A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection," *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1995.



TÜM MODELLER – GENEL KARŞILAŞTIRMA TABLOSU

Model	Accuracy	Precision (Macro)	Recall (Macro)	F1-Score (Macro)
EfficientNet-B0	0.9898	0.9867	0.9876	0.9872
ResNet-34	0.9524	0.9397	0.9456	0.9424
ResNet-50	0.9132	0.9170	0.9132	0.9134
DenseNet121 (Basit FT)	0.9598	0.9476	0.9575	0.9522
DenseNet121 (Kademeli FT)	0.9524	0.9363	0.9505	0.9426
ConvNeXt-Tiny	0.9709	0.9609	0.9696	0.9650
InceptionV3	0.9136	0.8900	0.8940	0.8910
AlexNet	0.9140	0.9161	0.9140	0.9145
ResNet18	0.9039	0.9080	0.9039	0.9045
CNN + Dropout (6 Katman)	0.7889	0.7598	0.7378	0.7478
CNN + Dropout (4 Katman)	0.7035	0.7035	0.6227	0.6479
Base CNN	0.6990	0.4887	0.6990	0.5752
MLP (Optimized)	0.5194	0.5675	0.5194	0.5254



BIOLOGICAL

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.664634	0.656627	0.660606	0.656627
CNN+Dropout (4 layer)	0.745500	0.550300	0.633200	0.968000
CNN+Dropout (6 layer)	0.759100	0.698000	0.727300	0.973700
ResNet18	0.953600	0.966400	0.960000	0.966400
AlexNet	0.934200	0.953000	0.943500	0.953000
DenseNet121 (Basit FT)	0.985000	0.985000	0.985000	0.998500
DenseNet121 (Kademeli FT)	0.970300	0.980000	0.975100	0.997500
ConvNeXtTiny	0.980100	0.985000	0.982500	0.998200
ResNet50	0.960000	0.953642	0.956811	0.953642
EfficientNetB0	0.987078	0.995988	0.991513	0.995988
ResNet34	0.947712	0.973154	0.960265	0.995953
InceptionV3	0.902400	0.980100	0.939700	0.980100
CNN+Batch	0.670000	0.770000	0.710000	0.670000
MLP Modeli	0.348900	0.651000	0.454300	0.651000

CARDBOARD

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.652968	0.558594	0.602105	0.558594
CNN+Dropout (4 layer)	0.726700	0.795600	0.759600	0.953500
CNN+Dropout (6 layer)	0.814500	0.817500	0.816000	0.965900
ResNet18	0.914200	0.894200	0.904100	0.894200
AlexNet	0.922800	0.916100	0.919400	0.916100
DenseNet121 (Basit FT)	0.982900	0.942500	0.962200	0.993200
DenseNet121 (Kademeli FT)	0.958800	0.956200	0.957500	0.992200
ConvNeXtTiny	0.967300	0.972600	0.969900	0.994400
ResNet50	0.928000	0.843636	0.883810	0.843636
EfficientNetB0	0.990148	0.991233	0.990690	0.991233
ResNet34	0.964029	0.978102	0.971014	0.994604
InceptionV3	0.893000	0.880000	0.886400	0.880000
CNN+Batch	0.770000	0.800000	0.780000	0.770000
MLP Modeli	0.526100	0.587600	0.555200	0.587600

GLASS

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.708791	0.553648	0.621687	0.553648
CNN+Dropout (4 layer)	0.695600	0.715200	0.705300	0.907300
CNN+Dropout (6 layer)	0.749500	0.806500	0.777000	0.928200
ResNet18	0.891400	0.873900	0.882500	0.873900
AlexNet	0.921300	0.891300	0.906100	0.891300
DenseNet121 (Basit FT)	0.961500	0.939500	0.950400	0.984800
DenseNet121 (Kademeli FT)	0.970100	0.900300	0.933900	0.980300
ConvNeXtTiny	0.983200	0.954200	0.968500	0.990400
ResNet50	0.873747	0.947826	0.909281	0.947826
EfficientNetB0	0.990862	0.991833	0.991347	0.991833
ResNet34	0.951724	0.900000	0.925140	0.977403
InceptionV3	0.895000	0.926100	0.910300	0.926100
CNN+Batch	0.730000	0.750000	0.740000	0.730000
MLP Modeli	0.684200	0.339100	0.453500	0.339100

METAL

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.322222	0.213235	0.256637	0.213235
CNN+Dropout (4 layer)	0.569100	0.457500	0.507200	0.954100
CNN+Dropout (6 layer)	0.610300	0.542500	0.574400	0.958500
ResNet18	0.674800	0.908500	0.774400	0.908500
AlexNet	0.762400	0.902000	0.826300	0.902000
DenseNet121 (Basit FT)	0.868800	0.941200	0.903500	0.989600
DenseNet121 (Kademeli FT)	0.826300	0.955900	0.886400	0.987400
ConvNeXtTiny	0.896900	0.980400	0.936800	0.993200
ResNet50	0.725275	0.862745	0.788060	0.862745
EfficientNetB0	0.970845	0.979412	0.975110	0.979412
ResNet34	0.867089	0.895425	0.881029	0.987521
InceptionV3	0.766500	0.836600	0.800000	0.836600
CNN+Batch	0.570000	0.440000	0.500000	0.570000
MLP Modeli	0.333300	0.215700	0.261900	0.215700

PAPER

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.431438	0.522267	0.472527	0.522267
CNN+Dropout (4 layer)	0.592900	0.595200	0.594100	0.930900
CNN+Dropout (6 layer)	0.734900	0.726200	0.730500	0.954500
ResNet18	0.856000	0.825400	0.840400	0.825400
AlexNet	0.861700	0.865100	0.863400	0.865100
DenseNet121 (Basit FT)	0.934500	0.976200	0.954900	0.992200
DenseNet121 (Kademeli FT)	0.960400	0.937500	0.948800	0.991400
ConvNeXtTiny	0.966500	0.943500	0.954800	0.992400
ResNet50	0.917749	0.841270	0.877847	0.841270
EfficientNetB0	0.988024	0.982143	0.985075	0.982143
ResNet34	0.959184	0.932540	0.945674	0.990894
InceptionV3	0.860900	0.908700	0.884200	0.908700
CNN+Batch	0.630000	0.680000	0.660000	0.630000
MLP Modeli	0.295100	0.428600	0.349500	0.428600

PLASTIC

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.493404	0.563253	0.526020	0.563253
CNN+Dropout (4 layer)	0.541400	0.724800	0.619800	0.910600
CNN+Dropout (6 layer)	0.712400	0.731500	0.721900	0.943300
ResNet18	0.885100	0.775200	0.826500	0.775200
AlexNet	0.876700	0.859100	0.867800	0.859100
DenseNet121 (Basit FT)	0.948300	0.924400	0.936200	0.987400
DenseNet121 (Kademeli FT)	0.926600	0.921900	0.924200	0.984800
ConvNeXtTiny	0.955100	0.964700	0.959900	0.991900
ResNet50	0.936000	0.782609	0.852459	0.782609
EfficientNetB0	0.987297	0.979335	0.983300	0.979335
ResNet34	0.896104	0.926174	0.910891	0.981788
InceptionV3	0.905900	0.772600	0.833900	0.772600
CNN+Batch	0.660000	0.660000	0.660000	0.660000
MLP Modeli	0.432200	0.396000	0.413300	0.396000

SHOES

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.659664	0.562724	0.607350	0.562724
CNN+Dropout (4 layer)	0.705600	0.508400	0.591000	0.929500
CNN+Dropout (6 layer)	0.755200	0.727300	0.741000	0.949100
ResNet18	0.946700	0.956200	0.951400	0.956200
AlexNet	0.935900	0.885500	0.910000	0.885500
DenseNet121 (Basit FT)	0.941700	0.982300	0.961600	0.992200
DenseNet121 (Kademeli FT)	0.935300	0.987300	0.960600	0.991900
ConvNeXtTiny	0.953800	0.992400	0.972700	0.994400
ResNet50	0.912226	0.976510	0.943274	0.976510
EfficientNetB0	0.991397	0.990895	0.991146	0.990895
ResNet34	0.939683	0.996633	0.967320	0.993255
InceptionV3	0.963500	0.973200	0.968300	0.973200
CNN+Batch	0.670000	0.650000	0.660000	0.670000
MLP Modeli	0.445400	0.356900	0.396300	0.356900

TRASH

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.487179	0.407143	0.443580	0.407143
CNN+Dropout (4 layer)	0.804900	0.464800	0.589300	0.969000
CNN+Dropout (6 layer)	0.740200	0.662000	0.698900	0.972700
ResNet18	0.791700	0.802800	0.797200	0.802800
AlexNet	0.802600	0.859200	0.829900	0.859200
DenseNet121 (Basit FT)	0.898000	0.926300	0.911900	0.991400
DenseNet121 (Kademeli FT)	0.866300	0.921100	0.892900	0.989400
ConvNeXtTiny	0.922700	0.942100	0.932300	0.993400
ResNet50	0.753247	0.811189	0.781145	0.811189
EfficientNetB0	0.975738	0.976769	0.976253	0.976769
ResNet34	0.888112	0.894366	0.891228	0.989545
InceptionV3	0.827100	0.769200	0.797100	0.769200
CNN+Batch	0.610000	0.580000	0.590000	0.610000
MLP Modeli	0.300000	0.464800	0.364600	0.464800

CLOTHES

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.798274	0.913580	0.852044	0.913580
CNN+Dropout (4 layer)	0.789200	0.918600	0.849000	0.912000
CNN+Dropout (6 layer)	0.896100	0.928700	0.912100	0.951800
ResNet18	0.988600	0.976200	0.982400	0.976200
AlexNet	0.981000	0.971200	0.976100	0.971200
DenseNet121 (Basit FT)	0.997100	0.978400	0.987700	0.993400
DenseNet121 (Kademeli FT)	0.996200	0.982200	0.989100	0.994200
ConvNeXtTiny	1.000000	0.982200	0.991000	0.995200
ResNet50	0.991139	0.978750	0.984906	0.978750
EfficientNetB0	0.996622	0.996809	0.996715	0.996809
ResNet34	0.997472	0.987484	0.992453	0.995953
InceptionV3	0.982400	0.977500	0.979900	0.977500
CNN+Batch	0.900000	0.910000	0.910000	0.900000
MLP Modeli	0.865600	0.749700	0.803500	0.749700

BATTERY

Model	Precision	Recall	F1-Score	Accuracy
Base CNN	0.601190	0.759399	0.671096	0.759399
CNN+Dropout (4 layer)	0.864200	0.496500	0.630600	0.972300
CNN+Dropout (6 layer)	0.825400	0.737600	0.779000	0.980100
ResNet18	0.875000	0.943300	0.907800	0.943300
AlexNet	0.917800	0.950400	0.933800	0.950400
DenseNet121 (Basit FT)	0.958500	0.978800	0.968600	0.997000
DenseNet121 (Kademeli FT)	0.952900	0.963000	0.957900	0.996000
ConvNeXtTiny	0.984000	0.978800	0.981400	0.998200
ResNet50	0.912752	0.951049	0.931507	0.951049
EfficientNetB0	0.989429	0.991525	0.990476	0.991525
ResNet34	0.985612	0.971631	0.978571	0.997976
InceptionV3	0.903400	0.916100	0.909700	0.916100
CNN+Batch	0.720000	0.610000	0.660000	0.720000
MLP Modeli	0.362300	0.680900	0.472900	0.680900

En iyi model ve gerekçesi

Elde edilen sonuçlar incelendiğinde en iyi performansı EfficientNet-B0 modelinin sergilediği görülmektedir. Model, %98.98 accuracy, %98.67 macro precision, %98.76 macro recall ve %98.72 macro F1-score değerleriyle diğer tüm modelleri açık bir farkla geride bırakmıştır. Özellikle macro ortalamaların yüksek olması, modelin veri setindeki tüm sınıflar üzerinde dengeli ve tutarlı bir performans sunduğunu göstermektedir.



Bu başarının temel nedeni, EfficientNet-B0'ın denge-li ölçeklendirme (compound scaling) yaklaşımıyla ağ derinliği, genişliği ve giriş çözünürlüğünü birlikte optimize etmesidir. Çözülen problemin görüntü tabanlı sınıflandırma olması ve veri setindeki görsel örüntülerin hem ince detaylar hem de global yapılar içermesi, EfficientNet-B0'ın bu çok ölçekli temsil gücünden maksimum verim almasını sağlamıştır. Ayrıca veri setinin, aşırı derin modeller gerektirmeyecek kadar ayırt edici görsel özellikler içermesi, EfficientNet-B0'ın daha büyük ve karmaşık modellere kıyasla aşırı öğrenmeye düşmeden daha iyi genelleme yapmasına katkı sağlamıştır.





Sonuç olarak, yüksek doğruluk, sınıflar arası dengeli performans ve genelleme kabiliyeti birlikte değerlendirildiğinde, bu problem ve veri seti özelinde EfficientNet-B0 en uygun ve en başarılı model olarak öne çıkmaktadır.

Appendix




Base modellerde oluşturulan grafikler Vize Raporu'nda olduğundan yeniden eklenmemiştir.




INCEPTION V3











ResNet50










ConvNeXt-Tiny













DenseNet121(Basit Fine-Tuning)










DenseNet121(Kademeli Fine-Tuning)











AlexNet











ResNet-18





EfficientNet-B0





ResNet-34

